Análisis de Datos

26.03.2026

Hugo Missael González Cruz

Análisis de Datos

Análisis de Datos es el proceso de inspeccionar, limpiar, transformar y modelar datos con el objetivo de descubrir información útil, fundamentar conclusiones y apoyar en la toma de decisiones.

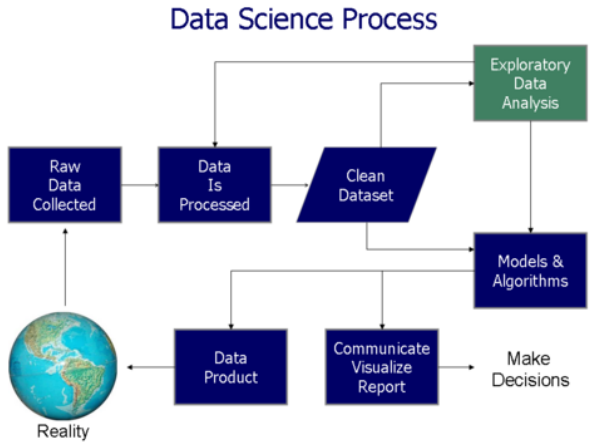

Reducción de Dimensión

El análisis de datos a menudo lidia con problemas en dimensiones grandes.

La hipotésis de la variedad

Los puntos de un conjunto de datos yacen en una variedad de menor dimensión que el espacio ambiente.

Como consecuencia, podemos caracterizar un conjunto de datos por menos variables de las que partimos. Por esta razón a la **reducción de dimensión** se le conoce también como **aprendizaje de variedades**.

En el proceso de análisis de datos, los métodos de RD son útiles:

- En análisis exploratorio, para comprender mejor la estructura de los datos
- En visualización, para interpretar/explicar los resultados.
- En preprocesamiento: Simplifica, reduce y limpia los datos para ser usados posteriormente.

PCA

Análisis de Componentes Principales (PCA) es un método *espectral* de reducción de dimensión que asume que los datos en una dimensión grande $x \in \mathbb{R}^d$ yacen en un variedad lineal y busca el subespacio lineal donde los datos proyectados tienen varianza máxima.

Consideramos un conjunto de datos:

$$X = [x_1, ..., x_n] \in \mathbb{R}^{d \times n}$$

El primer paso es centrar los datos:

$$\breve{X} = XH = X - \mu_x$$

donde

$$\mu_x = \frac{1}{n} \sum_{1}^{n} x_i$$

es la media de las columnas.

PCA (ii)

PCA busca proyectar los datos en el espacio lineal $\mathrm{col}(U)$. Para ello debemos hallar:

$$U = \left[u_1, \ldots, u_p\right] \in \mathbb{R}^{d \times p}$$

Con eso, la proyección de los datos centrados es:

$$\tilde{X} = U^\top \breve{X}$$

Con reconstrucción

$$\hat{X} = UU^\top \breve{X} + \mu_x = U\tilde{X} + \mu_x$$

La matriz de covarianza $S = \breve{X}\breve{X}^\top$.

El siguiente problema de optimización encuentra dicha matriz

$$\begin{aligned} \max_{U} \quad & \mathrm{tr}\left(U^\top S U\right) = \mathrm{var}\left(\tilde{X}\right) \\ \text{sujeto a} \quad & U^\top U = I \end{aligned}$$

PCA (iii)

El problema de optimización es equivalente a la descomposición en valores propios de S,

$$SU = U\Lambda$$

donde U son los vectores propios de S y Λ los valores propios. Además, los vectores y valores propios están ordenados de mayor a menor.

Llamamos **direcciones principales** a las columnas de U y a las columnas de la proyección $\tilde{X}$ **componentes principales**.

1. Si $\text{rank}(S) = d$ (tiene d valores propios distintos de cero), entonces $d = p$:
   - $U \in \mathbb{R}^{d \times d}$
   - $\tilde{X} \in \mathbb{R}^{d \times n}$

La proyeción en $\text{col}(U)$ equivale a una rotación en el espacio lineal original.

2. Si $\text{rank}(S) < d$ y $n > d$ entonces:
   - $U \in \mathbb{R}^{d \times p}$ y $\text{rank}(U) = p < d$
   - $\tilde{X} \in \mathbb{R}^{p \times n}$

PCA (iv)

Los datos están en un subespacio que no está disperso en todas las direcciones.

3. Si $\text{rank}(S) \leq n - 1 < d$, no hay suficientes puntos para representar al espacio original.

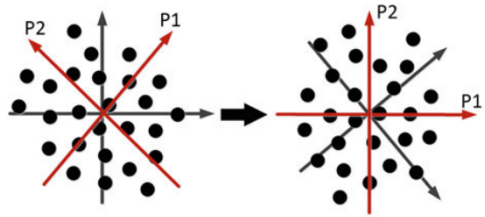

PCA (v)

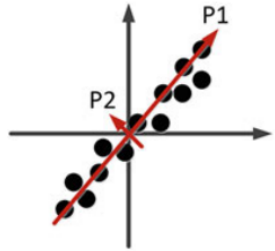

Se puede truncar la matriz U y seleccionar los $q < p$ vectores propios más relevantes. Siguiendo el siguiente criterio: Conservar los vectores propios tales que sus proporciones

$$\frac{\lambda_i}{\sum_{k=1}^{d} \lambda_k}$$

suman más de 0.8.

PCA (vi)

Ventajas

- Los componentes principales son combinaciones lineales de las variables originales.
- Podemos proyectar nuevos datos en los ejes principales.

Desventajas

- Funciona mejor si las variables están relacionadas linealmente.
- Debemos decidir el número de componentes principales a retener.

Ejemplo

Tenemos el conjunto de datos de las distintas medidas de billetes. Note que los datos están etiquetados como falsos o genuinos.

Status	Length	Left	Right	Bottom	Top	Diagonal
genuine	214.	130.	129.	7.4	10.7	142.
genuine	215.	130.	130.	8.3	10	142
genuine	216.	130.	130.	9	9.5	142.
genuine	215	130.	130.	9.1	10.2	141.
genuine	215.	130	130.	9.1	10.2	142.
genuine	215.	130	129.	7.8	10	141.
counterfeit	214.	130.	130.	9.7	11.7	140.
counterfeit	215.	130.	130.	11	11.5	140.

Graficamos todas las variables contra todas las variables

Ejemplo (ii)

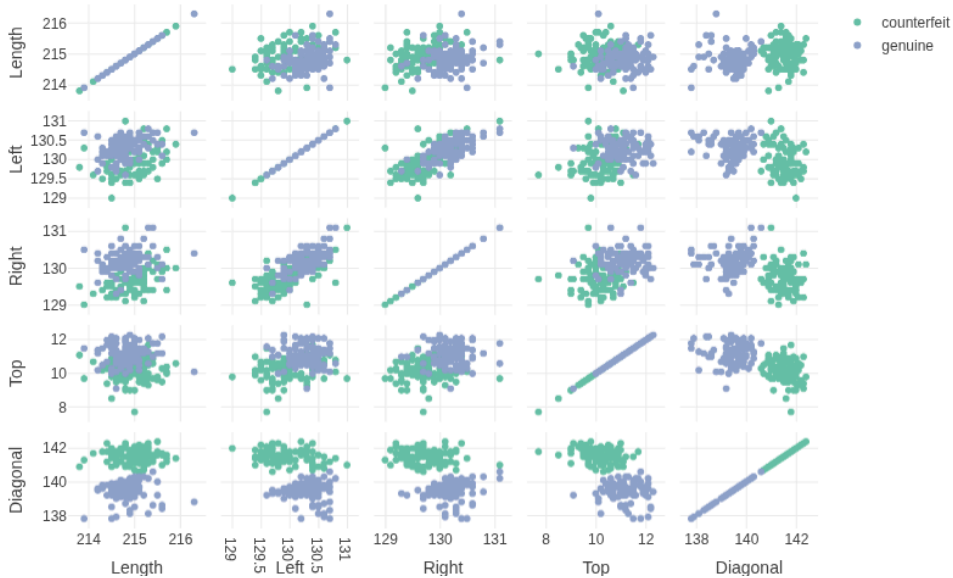
counterfeit
genuine
Length
Left
Right
Top
Diagonal
216
215
214
131
130.5
130
129.5
129
131
130
129
12
10
8
142
140
138
214
215
216
129
129.5
130
130.5
131
129
130
131
8
10
12
138
140
142

Ejemplo (iii)

Aplicamos PCA Los valores propios son:

blank	PCA1	PCA2	PCA3	PCA4	PCA5	PCA6
Variance	2.9455582	1.2780838	0.8690326	0.4497687	0.2686769	0.1888799
Proportion of Variance	0.4909	0.2130	0.1448	0.07496	0.04478	0.03148
Cumulative Proportion	0.4909	0.7039	0.8488	0.92374	0.96852	1.00000

Volvemos a graficar, ahora en las direcciones principales.

Ejemplo (iv)

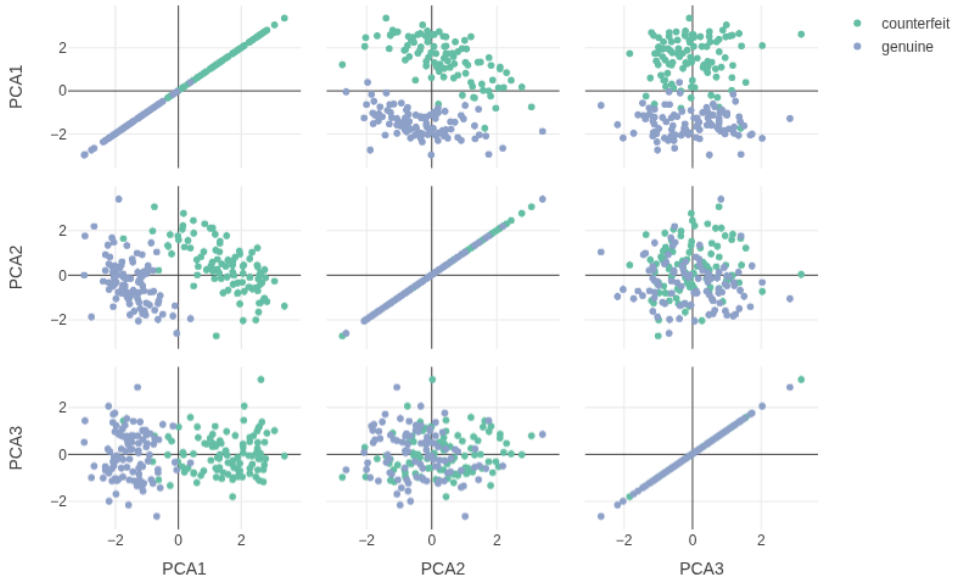
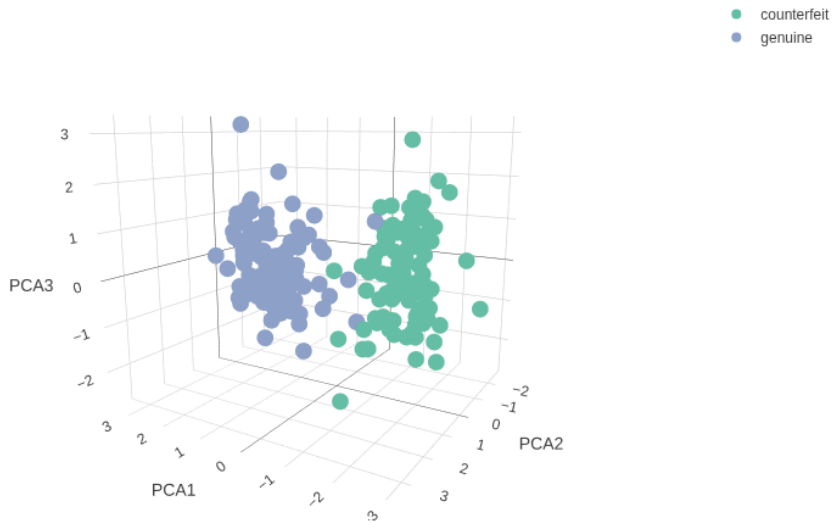
Ejemplo (v)